Universidad de La Sabana

Maestría en Inteligencia Artificial — Técnicas Avanzadas de Modelado con IA

Actividad 3 · Ejecución, optimización y validación comparativa

Presentado por: Claudia Maritza Soto Cárdenas · Álvaro David Jiménez Castro · Óscar Mauricio Mantilla Franco

INFORME TÉCNICO FINAL

Fases del proyecto	Fase 1 (Línea Base) + Fase 2 (Ablación incremental, 7 experimentos)
Video analizado	1364×764 px · 30 FPS · 1233 fotogramas (~41 seg) · cámara táctica dinámica
Mejor cobertura continua	Exp 6 (BoT-SORT + YOLO11s + ReID): track mediana 1030 fr, 165 m/jugadora, 0 ghost tracks
Mejor identidad consistente	Exp 7 (YOLO fine-tuned + ReID): 1.3× fragmentación, 7 ID switches (mínimo histórico)

1. Introducción y Planteamiento del Problema

El análisis cinemático del rendimiento físico en fútbol —distancias recorridas, zonas de esfuerzo, picos de velocidad— es insumo directo para la planificación de cargas de entrenamiento y la prevención de lesiones. La solución estándar de la industria son sistemas GPS de alta frecuencia (10–25 Hz) embebidos en chalecos, cuyo costo y logística limitan su adopción en categorías menores, formativas y de alto rendimiento femenino.

Este proyecto plantea una alternativa basada en visión por computador: dado un video de cámara táctica con movimiento dinámico (paneo), estimar las distancias recorridas por cada jugadora sin ningún sensor físico. El problema es desafiante por tres razones fundamentales:

- (1) La cámara se mueve: el desplazamiento en pantalla mezcla movimiento real con movimiento de cámara.
- (2) Las jugadoras se ocluyen y abandonan el encuadre, provocando pérdida y reasignación de identidades.
- (3) Sin datos GPS de referencia, las distancias absolutas tienen un error sistemático difícil de cuantificar.

1.1 Objetivo general

Diseñar, implementar y evaluar un pipeline de estimación de distancias recorridas por jugadoras de fútbol a partir de video de cámara táctica, usando YOLO, seguimiento multi-objeto (MOT) y compensación de movimiento global (GMC), documentando el proceso de mejora incremental mediante un estudio de ablación que incluye fine-tuning del detector y re-identificación por apariencia (ReID).

1.2 Alcance y limitaciones declaradas

El pipeline produce estimaciones comparables entre experimentos del mismo sistema. Las distancias absolutas tienen una incertidumbre del ±30–40 % por el error residual del GMC (Sección 7). Toda comparación cuantitativa es interna; no equivale a validación contra GPS.

2. Arquitectura del Sistema

El pipeline se organiza en etapas secuenciales con arquitectura modular y funcional: cada módulo expone funciones puras, lo que permite intercambiar componentes de forma independiente para el estudio de ablación.

Etapa	Módulo	Función	Parámetro clave (Exp 6)
1	**detector.py**	Detecta personas en cada fotograma (bounding boxes + confianza)	YOLO11s, imgsz=1536, conf=0.10 (Exp 7: YOLO fine-tuned)
2	**tracker.py (GMC)**	Estima transformación de cámara frame a frame; proyecta posición compensando el paneo	Homografía 8 DOF, RANSAC, 200 puntos
3	**tracker.py (MOT)**	Asocia detecciones con tracks; mantiene identidades a través de oclusiones; re-identifica por apariencia	BoT-SORT + ReID OSNet, track_buffer=600
4	**kinematics.py**	Suaviza trayectorias; filtra pasos físicamente imposibles; convierte píxeles a metros	deadband=1.5 m/s, max=12 m/s, smooth=9 fr
5	**track_merger.py**	Fusiona fragmentos del mismo jugador separados temporalmente	gap=450 fr, dist=300 px, 2 pasadas greedy
6	**projection.py**	Convierte desplazamiento en píxeles a metros con corrección de perspectiva	scale=0.0621 m/px, corrección lineal 1.5×

3. Diseño Experimental

Se adoptó una metodología de estudio de ablación incremental: partiendo de la línea base (Fase 1), cada experimento agrega exactamente un componente sobre el anterior, manteniendo fijas todas las demás variables. La semilla de reproducibilidad es SEED = 42. Los Experimentos 5–7 se ejecutaron en Google Colab (GPU Tesla T4) por requerimientos de memoria; Experimentos 1–4 en CPU local (Windows 11).

Exp.	Nombre	Componente aislado	Hipótesis de mejora
1	ByteTrack + YOLOv8s	Tracker ByteTrack, conf=0.10, imgsz=1536, polígono de cancha	Reducir fragmentación; mejorar recall de jugadoras lejanas
2	+ Filtro cinemático	Media móvil 9 fr + deadband 1.5 m/s + max_speed 12 m/s	Eliminar velocidades imposibles; aumentar cobertura de distancia
3	+ Scale calibrado	Scale factor 0.0621 m/px (refs. FIFA) + corrección perspectiva lineal	Mejorar precisión métrica absoluta
4	+ Color + Merge	K-Means K=3 (HSV torso) + Merge greedy 2 pasadas (gap=450 fr, 300 px)	Fusionar fragmentos del mismo jugador separados temporalmente
5 (*GPU)	OC-SORT + YOLO11s	OC-SORT (delta_t=5, inertia=0.3) + YOLO11s + GMC homografía 8DOF	Mantener identidad en oclusiones largas; mejorar recall
6 (*GPU)	BoT-SORT + YOLO11s + ReID	BoT-SORT con ReID OSNet (osnet_x0_25_msmt17.pt) + YOLO11s	Re-identificar jugadoras por apariencia; reducir switches y fragmentación
7 (*GPU)	YOLO fine-tuned + ReID	YOLO11s fine-tuned con pseudo-etiquetas (conf>0.5, split 80/20) + ReID	Detector especializado en el video; reducir falsas detecciones y fragmentación

El video de referencia es compartido por todos los experimentos: 1364×764 px, 30 FPS, 1233 fotogramas (~41 segundos), generado por una cámara táctica con paneo horizontal continuo.

4. Resultados — Fase 1: Línea Base

La Fase 1 implementó la configuración mínima funcional: YOLOv8n (nano), BoT-SORT con parámetros por defecto, GMC afín, sin filtros cinemáticos y sin restricción espacial. Su propósito es establecer el punto de referencia para medir el progreso de la Fase 2.

Categoría	Métrica	Valor (Fase 1)	Interpretación
Tracking	IDs únicos generados	**42**	1.9× fragmentación vs 22 esperadas

Categoría	Métrica	Valor (Fase 1)	Interpretación
Tracking	Track length mediana	**12 fr**	~0.4 seg — tracks muy cortos
Tracking	ID switches estimados	**20**	Reasignaciones frecuentes
Tracking	Ghost tracks	**1 (2.4 %)**	Trayectorias fragmentadas persistentes
Cinemática	Vel. máxima detectada	**44.5 m/s**	Físicamente imposible (>12 m/s)
Cinemática	% vel. imposibles	**1.1 %**	Sin filtro cinemático activo
Cinemática	Var. aceleración	**5.66**	Mayor jitter de todos los experimentos
Cobertura	Dist./jugadora en video	**3.4 m**	Muy baja por fragmentación extrema
Cobertura	Extrapolación 90 min	**0.45 km**	vs 9–13 km literatura FIFA (error ×20)
Cómputo	FPS (CPU local)	**4.22**	Modelo nano sin imgsz=1536

Diagnóstico: La baja distancia (3.4 m en 41 seg) no refleja movimiento real nulo, sino que la distancia real de cada jugadora está distribuida entre múltiples IDs fragmentados. La velocidad máxima de 44.5 m/s confirma que sin filtro cinemático el GMC residual genera desplazamientos ficticios. Estas métricas establecen el piso de referencia para medir el progreso de la Fase 2.

5. Resultados — Fase 2: Estudio de Ablación

La siguiente tabla consolida todas las métricas del ciclo experimental completo (8 configuraciones). Los colores indican semáforo de calidad respecto a rangos esperados para el dominio. Los experimentos marcados con (*) se ejecutaron en Google Colab (GPU Tesla T4).

Métrica	Baseline	Exp 1	Exp 2	Exp 3	Exp 4	Exp 5*	Exp 6*	Exp 7*
Componente	YOLOv8n BoT-SORT def.	ByteTrack tuneado	+Filtro cinemático	+Scale calibrado	+Color +Merge	OC-SORT +YOLO11s	BoT-SORT +YOLO11s+ReID	YOLO fine-tuned+ReID
CONTINUIDAD DE TRACKING (↓ mejor)								
IDs únicos	42	110	110	110	34	**38**	**37**	29
Fragmentación (×)	1.9	5	5	5	1.5	**1.7**	**1.7**	1.3
ID switches est.	20	88	88	88	12	**16**	**15**	7
Ghost tracks	1	2	2	2	1	**0**	**0**	0
CALIDAD CINEMÁTICA (↓ mejor)								
Vel. max (m/s)	44.5	20.1	12.0	12.0	12.0	**12.0**	**12.0**	12.0
% vel. imposibles	1.1	0.2	0.0	0.0	0.0	**0.0**	**0.0**	0.0
Var. aceleración	5.66	2.55	2.44	3.06	2.13	**1.70**	**1.75**	1.87
EXACTITUD Y COBERTURA (↑ mejor)								
Track mediana (fr)	12	104	104	104	552	**940**	**1030**	691
Dist./jugadora (m)	3.4	61.0	116.8	109.4	108.8	**162.5**	**165.2**	101.2
Extrap. 90 min (km)	0.4	8.0	15.3	14.4	14.3	**21.4**	**21.7**	13.3
RENDIMIENTO COMPUTACIONAL								
FPS procesamiento	4.22	13.90	17.57	17.78	14.16	**9.02**	**6.45**	10.50

(*) *Experimentos 5, 6 y 7 ejecutados en Google Colab (GPU Tesla T4). Notebook: notebooks/04_exp6_exp7_colab.ipynb. Resultados en data/processed/ablation_results.json.*

5.1 Interpretación: Experimentos 1–5

Exp 1 (ByteTrack tuneado): Salto más dramático en continuidad: track mediana 12 → 104 fr (+767 %). El aumento de resolución (imgsz=1536), la reducción del umbral (conf=0.10) y la restricción al polígono son los factores dominantes. La distancia sube de 3.4 a 61.0 m. El aumento de IDs (42 → 110) revela que ByteTrack con conf=0.10 es más agresivo en crear nuevos tracks, incrementando la fragmentación (1.9× → 5.0×).

Exp 2 (+ Filtro cinemático): Elimina el 100 % de velocidades físicamente imposibles. La distancia casi se duplica (61.0 → 116.8 m) porque el suavizado y el deadband recuperan pasos válidos antes descartados como ruido. Sin cambios en fragmentación, lo que confirma el aislamiento de variables.

Exp 3 (+ Scale calibrado): Reduce la distancia −6.3 % (116.8 → 109.4 m) al reemplazar 0.065 m/px por 0.0621 m/px. El factor manual sobreestimaba ~5 %. La corrección de perspectiva aumenta la varianza de aceleración (+25 %) al introducir un gradiente espacial.

Exp 4 (+ Color + Merge): Mayor impacto sobre la fragmentación: 110 → 34 IDs (−69 %), switches 88 → 12 (−86 %), track mediana 104 → 552 fr (+431 %). La fusión en dos pasadas captura pares transitivos que la pasada única no resolvería.

Exp 5 (OC-SORT + YOLO11s): Salto cualitativo en continuidad: track mediana 552 → 940 fr (+70 %). La aceleración llega a su mínimo global (1.70). La distancia sube a 162.5 m, reflejo del mayor tiempo de tracking continuo. Los 0 ghost tracks confirman la clasificación por color.

5.2 Interpretación: Experimentos 6–7 (ReID y Fine-Tuning)

Exp 6 (BoT-SORT + YOLO11s + ReID): La re-identificación por apariencia (OSNet) mejora la continuidad individual: track mediana 940 → 1030 fr (+9.6 %), ID switches 16 → 15. La distancia sube a 165.2 m (best cobertura del estudio). visualmente, Exp 6 identifica correctamente a las jugadoras con mucha más consistencia que experimentos previos: las identidades se mantienen incluso tras oclusiones prolongadas. El costo es el FPS más bajo (6.45), justificado por el proceso de extracción y comparación de descriptores ReID en cada frame.

Exp 7 (YOLO fine-tuned + BoT-SORT + ReID): El fine-tuning con pseudo-etiquetas logra la mejor fragmentación del estudio (1.3×) y los menos ID switches del estudio (7). Sin embargo, la distancia estimada baja a 101.2 m (−39 % vs Exp 6). La explicación es que el detector fine-tuned, entrenado con detecciones de alta confianza (conf>0.5), es más conservador: detecta menos jugadoras en frames donde están parcialmente ocluidas o lejos de la cámara. Esto produce menos tiempo de cobertura por jugadora, reduciendo la distancia acumulada. La trade-off es precisión (menos ruido, identidad más limpia) vs cobertura (menos tiempo de tracking). El FPS es mayor que Exp 6 (10.5 vs 6.45) porque el modelo fine-tuned tiene menor número de capas activas tras la poda del dominio.

Nota sobre pseudo-etiquetado: Se generaron pseudo-etiquetas ejecutando YOLO11s con conf=0.50 sobre los 1233 frames, conservando los que tuvieran ≥4 detecciones (~827 frames), con split 80/20 train/val. El entrenamiento se realizó con early stopping.

6. Comparación Consolidada: Línea Base → Mejores Configuraciones

La siguiente tabla resume los cambios más relevantes entre la línea base y las configuraciones finales del estudio. Se reportan Exp 6 (mejor cobertura continua) y Exp 7 (mejor identidad consistente) como dos opciones de uso según el objetivo.

Métrica	Baseline	Exp 6 (cobertura)	Exp 7 (identidad)	Cambio B→E6	Cambio B→E7	Interpretación
Track mediana (fr)	12	**1030**	**691**	×86	×58	Trayectorias mucho más largas
Fragmentación (×)	1.9	**1.7**	**1.3**	−11%	−32%	Exp 7 mejor identidad
ID switches	20	**15**	**7**	−25%	−65%	Exp 7 casi sin reasignaciones
Ghost tracks	1	**0**	**0**	−100%	−100%	Eliminados en ambos
Vel. max (m/s)	44.5	**12.0**	**12.0**	−73%	−73%	Plausibles en ambos

Métrica	Baseline	Exp 6 (cobertura)	Exp 7 (identidad)	Cambio B→E6	Cambio B→E7	Interpretación
Var. aceleración	5.66	**1.75**	**1.87**	−69%	−67%	Trayectorias suaves
Dist./jugadora (m)	3.4	**165.2**	**101.2**	×49	×30	Mayor cobertura en E6
Extrap. 90 min (km)	0.45	**21.8**	**13.3**	×48	×30	E7 dentro del rango FIFA
FPS	4.22	**6.45**	**10.5**	×1.5	×2.5	E7 más rápido

Nota sobre la extrapolación: Exp 6 extrapola a 21.8 km/90 min (por encima del rango FIFA de 9–13 km), lo que indica que el error residual del GMC contribuye sistemáticamente a la distancia acumulada en tracks de 1030 fr. Exp 7 extrapola a 13.3 km/90 min (dentro del rango FIFA), pero posiblemente por efecto de la reducción de cobertura del detector conservador, no por mayor precisión intrínseca. Ambas estimaciones deben considerarse con incertidumbre ±30–40 %.

7. Análisis de Errores, Limitaciones y Riesgos

El siguiente análisis distingue entre errores del sistema (comportamientos incorrectos dentro del diseño) y limitaciones estructurales (restricciones inherentes al problema o hardware).

Riesgo / Error	Nivel	Causa identificada	Mitigación implementada / Recomendación
Error residual GMC (~30–40 % distancia)	**ALTO**	Flujo óptico sparse deja 1–3 px/fr sistemáticos en dirección de paneo. A 30 FPS: ≥1.86 m/s, superior al deadband.	Aplicar homografía cancha↔imagen (H matrix ya calculada en 02_homography_builder.ipynb). Esta es la mitigación definitiva pendiente.
Fragmentación residual (1.3× en Exp 7)	**BAJO**	Detector fine-tuned más conservador: detecta menos jugadoras en frames lejanos, creando gaps de asociación.	Reducción de 1.9× (Baseline) a 1.3× (Exp 7) lograda. Para llegar a 1.0× se requiere aumentar densidad de pseudo-etiquetas o fine-tuning supervisado.
Sesgo de extrapolación por segmento corto	**MEDIO**	Pipeline validado sobre 41 seg (~0.76 % del partido). La extrapolación a 90 min supone intensidad homogénea.	Ejecutar sobre múltiples segmentos del partido completo y ponderar por duración de cada fase de juego.
Trade-off cobertura vs precisión (Exp 6 vs 7)	**MEDIO**	Exp 6 (165 m, tracks largos) vs Exp 7 (101 m, menos fragmentación). El fine-tuning reduce ruido pero también cobertura.	Para producción: usar Exp 6 si se prioriza cobertura total; Exp 7 si se prioriza identidad consistente por jugadora.
Falta de validación GPS	**ALTO**	Sin referencia GPS, las distancias absolutas son estimaciones con error sistemático no cuantificado.	Declarar incertidumbre explícita. Adquirir datos GPS (Catapult, STATSports) para validación cruzada.

7.1 Cuantificación del error residual del GMC

El flujo óptico sparse (Shi-Tomasi + Lucas-Kanade) en fondos de césped homogéneo produce un residual sistemático de 1–3 px/frame en la dirección de paneo. Con escala 0.0621 m/px a 30 FPS:

$$1 \text{ px/fr} \times 0.0621 \text{ m/px} \times 30 \text{ fr/s} = 1.86 \text{ m/s}$$

Este valor supera el deadband configurado (1.5 m/s), por lo que el paso se contabiliza. En Exp 6, con tracks medianos de 1030 fr: error acumulado estimado de **36–107 m por jugadora** sobre el segmento. La proyección homográfica al plano de la cancha (H matrix en models/homographies/H_matrix.npy) eliminaría este error de forma definitiva.

8. Recomendaciones de Uso y Despliegue

8.1 Condiciones mínimas de uso

El pipeline produce estimaciones comparables entre segmentos del mismo video. Las distancias absolutas tienen error ±30–40 %:

- Usar como métrica relativa (comparar intensidad entre partidos o posiciones) en lugar de distancias absolutas.
- No usar como sustituto de GPS para decisiones médicas sin calibración previa con datos de referencia.
- El video debe ser de cámara táctica con paneo suave; cámaras con vibración o zoom rápido degradan el GMC.

8.2 Selección de configuración según objetivo

Según el caso de uso:

- Usar Exp 6 (BoT-SORT + ReID) si se prioriza la cobertura de tiempo total y la continuidad de las trayectorias individuales. Mejor opción para análisis de distancia acumulada.
- Usar Exp 7 (YOLO fine-tuned + ReID) si se prioriza la consistencia de identidad a lo largo del partido, con mínimos cambios de ID. Mejor opción para análisis de patrones de movimiento individuales con alta fidelidad de identidad.
- Para producción a 90 min: integrar la homografía H al plano de cancha y procesar en segmentos de 5–10 min con overlap de 30 seg.

8.3 Instrucciones de ejecución

Comando	Descripción
`python src/models/baseline_tracker.py`	Fase 1 — genera baseline_distances.csv y baseline_tactical.mp4
`python src/models/advanced_tracker.py`	Fase 2 Exp 1–4 — genera ablation_results.json
`jupyter notebook notebooks/04_exp6_exp7_colab.ipynb`	Fase 2 Exp 6–7 en Google Colab (GPU) — genera ablation_results_completo.json
`jupyter notebook notebooks/02_homography_builder.ipynb`	(Re)calcula la homografía H; guarda H_matrix.npy

9. Conclusiones

El estudio demuestra que la estimación de distancias en fútbol mediante visión por computador es viable (parcialmente) con GPU de consumo y software de código abierto. Los hallazgos principales:

1. El ajuste de resolución de inferencia (imgsz=1536) y la restricción al polígono de cancha son los factores de mayor impacto en continuidad (track mediana: 12 → 104 fr, +767 %, Baseline → Exp 1).

2. El filtro cinemático (deadband + max_speed) es el componente de mayor impacto en cobertura de distancias (61.0 → 116.8 m, +91 %, Exp 1 → Exp 2).

3. La fusión de trayectorias en 2 pasadas es el componente de mayor impacto en fragmentación (110 → 34 IDs, −69 %; switches: 88 → 12, −86 %, Exp 3 → Exp 4).

4. La combinación OC-SORT + YOLO11s (Exp 5) y BoT-SORT + ReID (Exp 6) logran la mejor continuidad individual (track mediana 1030 fr en Exp 6, ×86 respecto al Baseline).

5. El fine-tuning con pseudo-etiquetas (Exp 7) logra la mejor consistencia de identidad del estudio (1.3× fragmentación, 7 switches), pero a costa de menor cobertura (101.2 m vs 165.2 m de Exp 6). La elección entre Exp 6 y Exp 7 depende del caso de uso.

6. La limitación principal no resuelta es el error residual del GMC (~1–3 px/fr). Su solución definitiva —proyección al plano de la cancha mediante homografía— es implementable con los artefactos ya existentes en el repositorio.

10. Declaración de Uso de Herramientas de IA

De acuerdo con la política de transparencia de la Universidad de la Sabana, se declara el uso de las siguientes herramientas de inteligencia artificial:

Herramienta	Uso específico	Revisión humana aplicada
Claude (Anthropic)	Revisión de código Python/Node.js del pipeline, análisis de errores, redacción de este informe y la bitácora técnica.	Todo el código fue ejecutado, inspeccionado y validado contra los resultados experimentales. La interpretación es autoría del grupo 1.
Ultralytics YOLO	Detección de personas (YOLOv8n, YOLOv8s, YOLO11s, YOLO fine-tuned) y trackers integrados (BoT-SORT, ByteTrack, OC-SORT). Pesos preentrenados en COCO. Exp 7: fine-tuning supervisado con pseudo-etiquetas generadas desde el video analizado.	Los parámetros fueron ajustados con base en análisis de resultados. El proceso de fine-tuning fue diseñado, ejecutado y validado por el grupo.
OSNet (torchreid)	Modelo de re-identificación por apariencia (osnet_x0_25_msmt17.pt) preentrenado en MSMT17. Usado en Exp 6 y 7 via Ultralytics BoT-SORT+ReID.	Los resultados de re-identificación fueron evaluados cuantitativamente (ID switches, fragmentación) y cualitativamente (revisión visual del video).
Google Colab	Entorno de GPU para ejecutar Exp 5–7 cuyo costo computacional superaba la capacidad local.	Los resultados fueron descargados y contrastados con los experimentos locales.

11. Referencias

[1] FIFA (2021). Physical demands in women's football. FIFA Technical Report.

[2] Zhang, Y. et al. (2022). ByteTrack: Multi-Object Tracking by Associating Every Detection Box. ECCV 2022.

[3] Cao, J. et al. (2023). Observation-Centric SORT: Rethinking SORT for Robust Multi-Object Tracking. CVPR 2023.

[4] Aharon, N. et al. (2022). BoT-SORT: Robust Associations Multi-Pedestrian Tracking. arXiv:2206.14651.

[5] Zhou, K. et al. (2019). Omni-Scale Feature Learning for Person Re-Identification (OSNet). ICCV 2019.

[6] Bernardin, K., Stiefelhagen, R. (2008). Evaluating Multiple Object Tracking: The CLEAR MOT Metrics. EURASIP JIVP.

[7] Jocher, G. et al. (2023). Ultralytics YOLO. https://github.com/ultralytics/ultralytics

12. Dependencias del Entorno

Librería / Herramienta	Versión	Función en el pipeline	Instalación
Python	3.10.22	Entorno de ejecución	conda create -n futbol python=3.10
Ultralytics YOLO	8.4.0 / 11.x	Detección + tracker integrado	pip install ultralytics
OpenCV	4.x	Lectura de video, GMC, homografía	pip install opencv-python
NumPy	≥1.24	Álgebra lineal, operaciones de array	pip install numpy
scikit-learn	1.x	K-Means para clasificación de equipos	pip install scikit-learn
PyYAML	6.x	Generación dinámica de configs tracker	pip install pyyaml
pandas	2.x	Manipulación de CSV por frame	pip install pandas
matplotlib	3.x	Visualización de métricas (notebooks)	pip install matplotlib
psutil	5.x	Monitoreo de RAM durante ejecución	pip install psutil

Entorno: *conda create -n futbol python=3.10.22 · pip install -r requirements.txt · SEED=42 · Windows 11 / Google Colab GPU T4.*